



Universidad Nacional Autónoma de México

Escuela Nacional de Estudios Superiores

Unidad Morelia



Ante Proyecto de:
**Análisis Estadístico de Valores Nutricionales por Tipo
de Dieta**

PRESENTA:

Alexis Uriel Aguilar Uribe

PROFESORES:

Dra. María Del Río Francos

Dr. César Andrés Torres Miranda

GRADO

Licenciatura en Tecnologías para la Información en Ciencias

Asignatura: Estadística Descriptiva e Inferencial

A: 21 de Mayo del 2025

Índice

1. Presentación de los Datos	2
1.1. Fuente de Datos	2
1.2. Interés del Estudio	2
1.3. Variables del Conjunto de Datos	2
2. Estadística Descriptiva	4
2.1. Descripción de los Valores de las Variables	4
2.2. Medidas de Tendencia Central y Dispersión	5
2.3. Estratificación de Valores Cuantitativos	6
2.3.1. Dieta DASH	6
2.3.2. Dieta Keto	7
2.3.3. Dieta Mediterránea	8
2.3.4. Dieta Paleo	9
2.3.5. Dieta Vegana	10
2.3.6. Gráfico de Cajas y Bigotes de la distribución de Macronutrientes por Dieta	11
3. Muestreo e Intervalos de Confianza	13
3.1. Muestreo Aleatorio Simple	13
3.1.1. Resultados del Muestreo	13
3.1.2. Z-Scores del Muestreo	13
3.1.3. Tabla de Frecuencias	14
3.1.4. Medidas de Tendencia Central y Dispersión Muestrales	14
3.1.5. Comparativa con las Medidas Poblacionales	14
3.2. Muestreo Aleatorio Estratificado	15
3.2.1. Resultados del Muestreo	15
3.2.2. Z-Scores del Muestreo	15
3.2.3. Tabla de Frecuencias	16
3.2.4. Medidas de Tendencia Central y Dispersión Muestrales	16
3.2.5. Comparativa con las Medidas Poblacionales	17

1. Presentación de los Datos

1.1. Fuente de Datos

El conjunto de datos con el que se está trabajando para este trabajo se encuentra en [1], publicado por la comunidad de Kaggle. Los datos consisten de un conjunto de recetas de diferentes dietas y cocinas, además incluye información de los macronutrientes de cada receta.

[1] Aunque en la descripción ni en los metadatos del conjunto de datos se haga mención de las fuentes explícitas de los datos ni el objetivo de esta extracción, sí cuenta con una sección de cómo usar el conjunto de datos, ideas de investigación y reconocimientos.

De los apartados de cómo usar el conjunto de datos e ideas de investigación, se encuentra una idea, implícita, de la información que se quería estudiar. La principal información de interés se vuelve que es: el crear planes alimenticios saludables, ya sea usando las recetas proporcionadas o creando unas nuevas basadas en una dieta y cocina, y el estudiar la relación entre dieta y salud.

Del apartado de reconocimientos, se concluye que las recetas fueron proporcionadas por diferentes creadores de las mismas y demás contribuidores al conjunto de datos.

1.2. Interés del Estudio

Se consultó [2] en sus capítulos 4 y 8, de donde se proporciona un mejor entendimiento de la importancia de los macronutrientes y una descripción general de las dietas en este trabajo, resultando interesante que en cada dieta se consumen diferentes alimentos y productos con ciertas características para ya sea respetar alguna creencia, fundamento o cota de macronutrientes. De esto último, proporciona un indicio de que existe una diferencia entre las dietas a nivel de sus aportes nutricionales, por lo tanto, lo que se quiere realizar es probar esta diferencia de manera significativa haciendo uso de la estadística.

1.3. Variables del Conjunto de Datos

El conjunto de datos consta de las siguientes variables. Se menciona su nombre, el tipo de variable y sus valores (en total y únicos):

Variable	Nombre	Tipo	Cantidad de Datos	Valores Únicos
1	Diet_type	Cualitativa Nominal	7806	5
2	Recipe_name	Cualitativa Nominal	7806	7062
3	Cuisine_type	Cualitativa Nominal	7806	19
4	Protein(g)	Cuantitativa Continua	7806	6060
5	Carbs(g)	Cuantitativa Continua	7806	6618
6	Fat(g)	Cuantitativa Continua	7806	6322

La variable Recipe_Name no es relevante para este trabajo pero figura dentro del dataset.

2. Estadística Descriptiva

Debido a que cada receta puede aportar una amplia variedad de valores en sus macronutrientes, esto podría dificultar la comparación entre los aportes nutricionales de las dietas. Por ello, para reducir este impacto de sesgo, se aplicó una normalización a los valores, es decir, los macronutrientes de cada receta se dividió por el total de macronutrientes que aportaba la receta, para así manejar los aportes proporcionales de cada macronutriente en cada una de las recetas.

2.1. Descripción de los Valores de las Variables

Para el presente trabajo se harán uso de las siguientes variables, se acompañan con una descripción de su significado:

- **Diet_type**: Variable que representa el tipo de dieta (DASH, keto, mediterránea, paleo, vegana) a la que pertenece una receta. Con esta variable se va permitir estratificar las recetas y estudiarlas de una manera más granular, es decir, por tipo de dieta para llegar a conjurar hipótesis sobre lo qué está pasando en una dieta o entre las diferentes dietas.
- **Cuisine_type**: Variable que representa a qué (estilo de) cocina o región (mexicana, americana, italiana) pertenece una receta. Al usarla va a permitir el comparar cómo son las recetas de una dieta en comparación con otras regiones, en específico el cómo se compara la dieta mediterránea en el mediterráneo en comparación con otras regiones geográficas.
- **Protein(g)**: Después de la transformación, representa el porcentaje, respecto al total de macronutrientes, de proteínas que son aportados por una receta. El usar las proteínas se va a permitir la comparación entre diferentes dietas, siendo esto el eje central del trabajo
- **Carbs(g)**: Después de la transformación, representa el porcentaje, respecto al total de macronutrientes, de carbohidratos que son aportados por una receta. Siendo otro de los macronutrientes de una comida, se vuelve relevante para la comparación entre recetas y dietas.
- **Fat(g)**: Después de la transformación, representa el porcentaje, respecto al total de macronutrientes, de grasas que son aportados por una receta. Y el último macronutriente, como en los anteriores, se vuelve una variable relevante para la comparación entre dietas.

2.2. Medidas de Tendencia Central y Dispersión

Realizando el resumen de las medidas, se tiene:


Medida	Carbs(g)	Protein(g)	Fat(g)
Media	0.433471	0.234762	0.331767
Q_1	0.205251	0.110188	0.184583
Q_2	0.432028	0.190931	0.314359
Q_3	0.635058	0.338059	0.464532
Desviación Estándar	0.256032	0.163886	0.194920
Mínimo	0.000330	0.000000	0.000000
Máximo	1.000000	0.887557	0.997940
Asimetría de Fisher	0.189556	0.922401	0.461455

Debido a que son medidas sobre todos los datos, sin estratificar, se tiene que no hay una referencia de lo que se espera obtener y parte de la información que contienen queda diluida o desvanecida. Esto debido a que las dietas como la vegana es baja en proteínas y la keto en carbohidratos [2], por lo que cualquier suposición no se podría sostener sobre todos las dietas.

Aún así, se reportan bajos valores en proteínas y grasas en comparación con los carbohidratos si se hace uso de los cuartiles Q_1 y Q_2 , dicho así: el cincuenta por ciento de las recetas tienen entre 11,01 % y 33,80 % de proteínas y entre 18,45 % y 46,45 % de grasas, en comparación con entre 20,52 % y 63,50 % de carbohidratos. Esto es un indicio de que las recetas, en general, tienden a ser altas en carbohidratos entre las diferentes dietas y cocinas; mientras que son bajas en proteínas.

Este último punto puede ser apoyado si se considera la media de los macronutrientes, que siguen este prototipo de aportes dominantes de carbohidratos.

Si se gráfica la distribución de los macronutrientes se tiene que, debido a la asimetría, contienen datos atípicos en proteínas y grasas en una región positiva respecto a la mediana, y esto se relaciona con lo mencionado de que una receta no tiende a una alta cantidad de proteínas o de grasas. Y se puede apreciar como justamente existe un alta concentración de recetas en una intervalo pequeño de valores, en comparación con los carbohidratos que se encuentran distribuidos sobre una región más amplia; esto último permite que no existan datos atípicos.



Debido a que existe la presencia de datos atípicos, lo más adecuado es tratarlos de manera estratificada, por tipo de dieta. Esto debido a que tratarlos de manera general podría evocar que ciertas dietas queden menos representadas en comparación con otras o que incluso se pierda información para consecuentes procesos. Y al tratar los valores atípicos dentro de cada dieta permite reducir el impacto de perder información valiosa y se siga conservando las recetas relevantes para una dieta.

2.3. Estratificación de Valores Cuantitativos

La variable Diet_type es la principal que se emplea para estratificación de las recetas, debido a que permite separarlas según una criterio bien definida, a qué dieta pertenece. Para cada una de las cinco dietas se presentan los datos tabulados de sus medidas de tendencia central y dispersión junto con su histograma de los valores en sus macronutrientes.

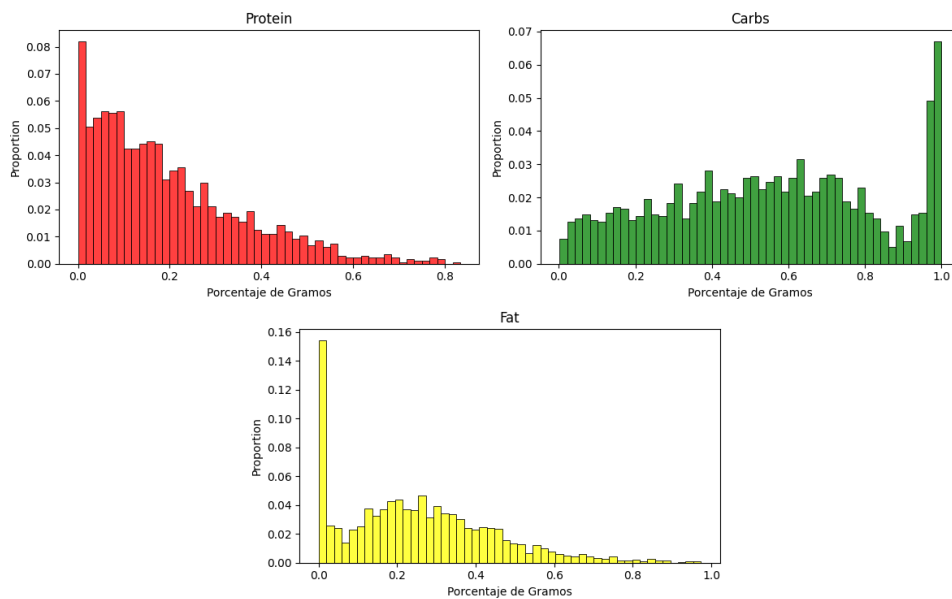
2.3.1. Dieta DASH

una receta de esta dieta tendrá que, en promedio, el 55 % de sus macronutrientes sons carbohidratos (provenientes de frutas, vegetales y granos enteros); el 25 % son grasas que, por su naturaleza, son saludables; y el 20 % son proteínas, las cuáles provienen de carnes margas.

Medida	Carbs(g)	Protein(g)	Fat(g)
Media	0.549425	0.196241	0.254334
Q_1	0.331143	0.068931	0.103381
Q_2	0.555219	0.156626	0.234742
Q_3	0.757917	0.282629	0.371292
Desviación Estándar	0.278850	0.162871	0.194078
Mínimo	0.001526	0.000000	0.000000
Máximo	1.000000	0.833467	0.973404
Asimetría de Fisher	-0.057984	1.101171	0.732534

Debido a que existe un sesgo positivo notable en las contribuciones de proteínas y grasas, se tiene que las recetas van a tender a tener bajos aportes de estos macronutrientes y que si tienen un alto aporte se consideraría una receta atípica dentro de la dieta.

Dieta: dash



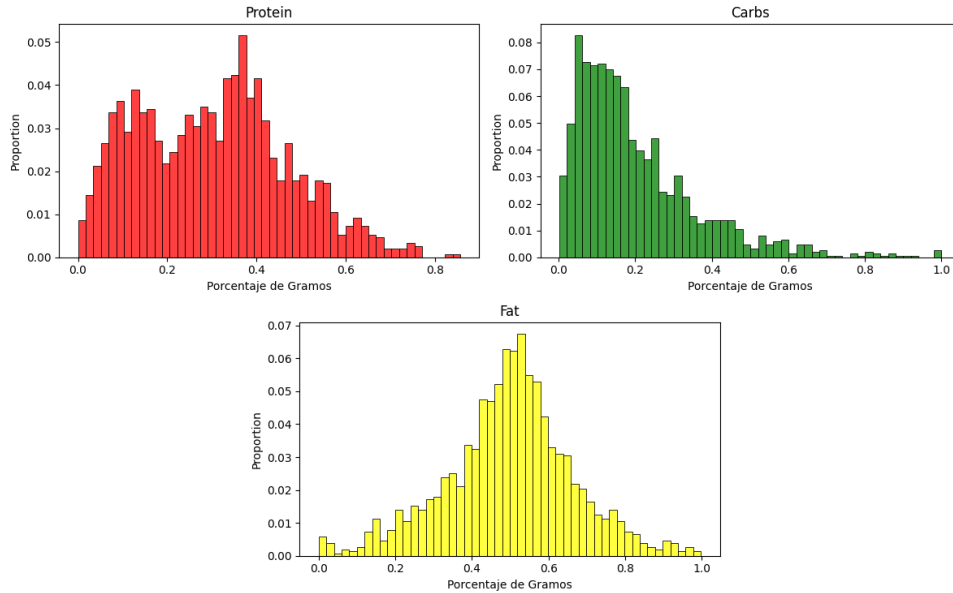
2.3.2. Dieta Keto

Una receta de esta dieta tendrá que, en promedio, el 50 % de sus macronutrientes son grasas, esto se relaciona con el hecho de que se intenta inducir la ketosis (principio en que se basa esta dieta); el 30 % son proteínas, notando que se intenta reducir el consumo de carbohidratos; y el 20 % son carbohidratos, resaltando ser una dieta baja en carbohidratos.

Medida	Carbs(g)	Protein(g)	Fat(g)
Media	0.200879	0.301777	0.497344
Q_1	0.085517	0.158284	0.405354
Q_2	0.157348	0.302900	0.505751
Q_3	0.267535	0.409453	0.591887
Desviación Estándar	0.160609	0.167027	0.166572
Mínimo	0.002060	0.000000	0.000000
Máximo	1.000000	0.856868	0.997940
Asimetría de Fisher	1.634945	0.314795	-0.147406

Como la proporciones de carbohidratos cuenta con un sesgo positivo, se tiene que refuerza el hecho de ser una dieta baja en carbohidratos, pero además que existen recetas con una alta contribución de este macronutriente. De los aportes de grasas, se observa que su sesgo es despreciable implicando que existen recetas tanto con aportes altos de este macronutriente (lo que se busca) mientras que hay recetas que una contribución baja o nula del mismo, esto es indicativo de que estas recetas no pertenecen a esta dieta solamente considerando la contribución de este macronutriente.

Dieta: keto




2.3.3. Dieta Mediterránea

Una receta de esta dieta tendrá que, en promedio, el 42 % de sus macronutrientes son carbohidratos, esto debido a un alto consumo de productos como, frutas, vegetales y granos enteros; el 30 % son grasas, resaltando un alto consumo de nueces y aceite de oliva, como también un

consumo moderado de pescado; y el 28 % son proteínas, vinculado con un consumo moderado de pescado y aves de corral, y un bajo consumo de carnes rojas.

Medida	Carbs(g)	Protein(g)	Fat(g)
Media	0.424493	0.279357	0.296150
Q_1	0.249955	0.159633	0.180357
Q_2	0.439382	0.227883	0.268336
Q_3	0.607531	0.377820	0.390404
Desviación Estándar	0.214325	0.162853	0.160783
Mínimo	0.006733	0.005036	0.001731
Máximo	0.992746	0.887557	0.968722
Asimetría de Fisher	-0.096055	0.955922	0.869493

La proporción de proteínas está segada positivamente y junto con una alta acumulación de recetas con bajo consumo de proteínas, se tiene que esta dieta figura como una con bajo consumo de alimentos ricos en proteínas.



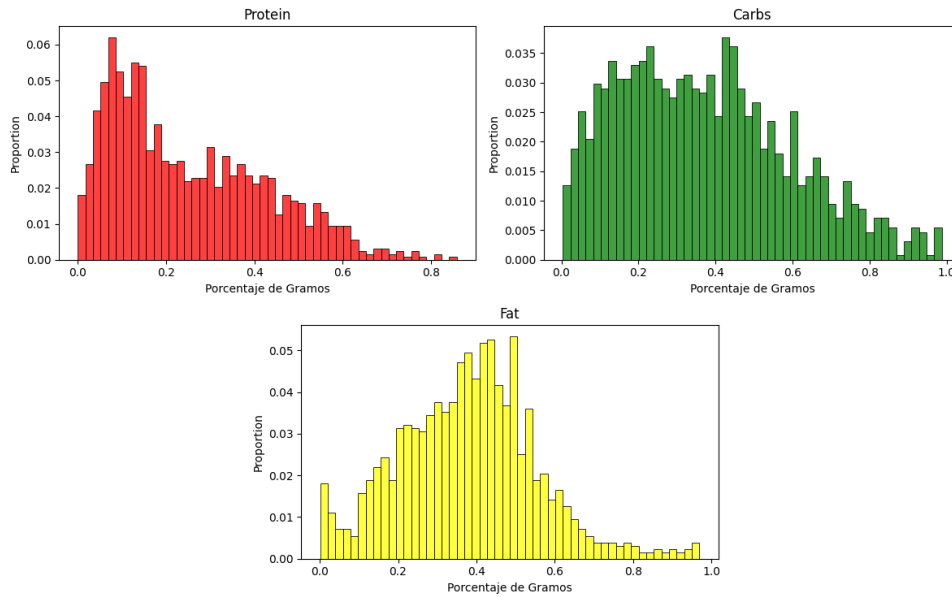
2.3.4. Dieta Paleo

Una receta de esta dieta tendrá que, en promedio, el 38 % de sus macronutrientes son grasas y el 37 % son carbohidratos, esto se relaciona con el consumo de productos como frutas, vegetales, nueces y semillas; y el 25 % son proteínas cuyas principales fuentes son carnes magras y pescado.

Medida	Carbs(g)	Protein(g)	Fat(g)
Media	0.371307	0.249693	0.379000
Q_1	0.192399	0.102963	0.256579
Q_2	0.351300	0.205532	0.382447
Q_3	0.515054	0.375392	0.488116
Desviación Estándar	0.221506	0.175031	0.175471
Mínimo	0.003612	0.000000	0.001404
Máximo	0.987368	0.858503	0.968835
Asimetría de Fisher	0.488656	0.711408	0.312673

Se observa como las recetas tienden a tener una contribución moderada de carbohidratos y grasas, esto se relaciona con los principales alimentos que son consumidos en esta dieta.

Dieta: paleo




2.3.5. Dieta Vegana

Una receta de esta dieta tendrá que, en promedio, el 60% de sus macronutrientes son carbohidratos, que provienen de fuentes como vegetales, frutas, cereales y legumbres; el 25% son grasas, relacionadas con el consumo de nueces y semillas; y el 15% son proteínas, esto debido a un nulo consumo de alimentos de origen animal y que estas fuentes son reemplazadas por fuentes vegetales.

Medida	Carbs(g)	Protein(g)	Fat(g)
Media	0.593968	0.148489	0.257543
Q_1	0.504070	0.085339	0.142575
Q_2	0.626246	0.139688	0.231518
Q_3	0.714679	0.190381	0.344529
Desviación Estándar	0.171203	0.086088	0.160277
Mínimo	0.000330	0.001921	0.000112
Máximo	0.986872	0.647416	0.994887
Asimetría de Fisher	0.189556	0.922401	0.461455

De las proporciones de proteínas, se resalta una alta acumulación de recetas con bajos aportes de proteínas, esto hace de esta dieta una con bajo consumo de proteínas. Lo último debido a que las principales fuentes proteínas son animales y haciendo que los aportes de carbohidratos sean altos en comparación con los otros dos macronutrientes.


Dieta: vegan



2.3.6. Gráfico de Cajas y Bigotes de la distribución de Macronutrientes por Dieta

Se anexan las gráficas de cajas y bigotes de las distribuciones de los macronutrientes por dieta para apoyar las observaciones realizadas anteriormente.

Distribución de Macronutrientes por Dieta



3. Muestreo e Intervalos de Confianza

Como las tres variables cuantitativas tienen el mismo nivel de relevancia, se opta por usar los Carbs(g) como atributo para el Muestreo. Y para ambos muestreos se realizan de tamaño 50 y, usando la Regla de Sturges, se emplean 7 clases o bins.

3.1. Muestreo Aleatorio Simple

3.1.1. Resultados del Muestreo

0.17269271	0.46650541	0.75534765	0.47087379	0.63277125
0.07006336	0.05484247	0.65481006	0.16118891	0.2385986
0.4684997	0.24332505	0.62191414	0.34102783	0.62236612
0.39206706	0.08786462	0.37490208	0.03025985	0.46368715
0.50368913	0.25911022	0.64134393	0.62119952	0.67296013
0.69099174	0.5093633	0.3897762	0.50870391	0.62610896
0.16637611	0.00205997	0.83795162	0.70500232	0.39452352
0.96228571	0.3650539	0.73331589	0.2995115	0.17188455
0.7579386	0.35745213	0.5351373	0.68094919	0.19350238
0.32026529	0.62170193	0.13598024	0.96879183	0.30912958

3.1.2. Z-Scores del Muestreo

Se tiene que la media muestral \bar{x} es 0,445313 y la desviación estándar muestral s es 0,246293.

-1.10689678	0.08604412	1.25880389	0.10378063	0.76111813
-1.52359336	-1.58539332	0.85060029	-1.15360459	-0.83930511
0.09414135	-0.82011471	0.717036	-0.42342106	0.71887111
-0.21619111	-1.45131653	-0.28588451	-1.68520391	0.07460139
0.23701778	-0.75602365	0.79592498	0.71413449	0.92429335
0.99750546	0.26005608	-0.22549249	0.25737883	0.73406782
-1.13254349	-1.79970131	1.59419324	1.05439133	-0.20621739
2.09901562	-0.32587018	1.16935033	-0.59198603	-1.11017805
1.2693237	-0.35673498	0.36470391	0.95673061	-1.02240518
-0.50772129	0.71617437	-1.25595705	2.12543183	-0.55293458

3.1.3. Tabla de Frecuencias

Marca de Clase	Puntaje Z	Frecuencia Absoluta	Frecuencia Relativa	Frecuencia Acumulada
0.071112	-1.519335	6.000000	0.120000	0.120000
0.209217	-0.958601	8.000000	0.160000	0.280000
0.347321	-0.397868	10.000000	0.200000	0.480000
0.485426	0.162865	8.000000	0.160000	0.640000
0.623530	0.723599	11.000000	0.220000	0.860000
0.761635	1.284332	4.000000	0.080000	0.940000
0.899740	1.845065	3.000000	0.060000	1.000000


3.1.4. Medidas de Tendencia Central y Dispersión Muestrales

Medida	Carbs(g)
Media	0.445313
Q_1	0.247271
Q_2	0.465096
Q_3	0.631106
Desviación Estándar	0.246293
Mínimo	0.002060
Máximo	0.968792
Asimetría de Fisher	0.077583

3.1.5. Comparativa con las Medidas Poblacionales

En algunas métricas como lo son la media, el primer y segundo cuartil, la desviación estándar, el máximo y la asimetría muestrales son diferentes de sus respectivos valores poblacionales. De los valores, era esperado que todos difieran aunque fuera un poco, salvo la media; para probar esto último sería necesario de aplicar una prueba de estimación.

Si se compara con la distribución poblacional, existe la distribución de muestra se conserva hasta cierto punto.



3.2. Muestreo Aleatorio Estratificado

3.2.1. Resultados del Muestreo

0.44793647	0.18250769	0.63935358	0.21435184	0.91825902
0.70068017	0.55288489	0.49903342	0.74194743	0.39776892
0.68474824	0.21756679	0.64524101	0.11898573	0.11534155
0.51769646	0.84650821	0.08359541	0.24333481	0.42687973
0.04969789	0.6525685	0.09963134	0.13678711	0.01271082
0.60119711	0.53384367	0.71907757	0.58809768	0.37297297
0.61700427	0.75929204	0.34345027	0.15223487	0.57504277
0.69714352	0.32857582	0.39527363	0.19990062	0.30321616
0.3849578	0.65746746	0.69443097	0.65933286	0.42047204
0.37633321	0.7136477	0.53091451	0.63226859	0.50493571

Leyenda de colores: DASH, Keto, Mediterránea, Paleo y Vegana.

3.2.2. Z-Scores del Muestreo

Se tiene que la media muestral \bar{x} es 0,458142 y la desviación estándar muestral s es 0,233125.

-0.04377718	-1.18234679	0.77731576	-1.04574978	1.97369417
1.04037915	0.40640414	0.17540563	1.21739704	-0.2589733
0.97203835	-1.03195909	0.80257021	-1.45482732	-1.47045922
0.25546167	1.66591559	-1.60663578	-0.92142592	-0.13410111
-1.75204084	0.83400182	-1.5378489	-1.37846742	-1.91069868
0.61364176	0.32472592	1.11929568	0.55745111	-0.36533674
0.68144734	1.29179758	-0.49197579	-1.3122035	0.50145144
1.0252085	-0.55578048	-0.26967698	-1.10773898	-0.66456198
-0.31392726	0.85501613	1.0135729	0.86301786	-0.16158718
-0.35092284	1.096004	0.31216114	0.74692438	0.20072383

Leyenda de colores: **DASH**, **Keto**, **Mediterránea**, **Paleo** y **Vegana**.

3.2.3. Tabla de Frecuencias

Marca de Clase	Puntaje Z	Frecuencia Absoluta	Frecuencia Relativa	Frecuencia Acumulada
0.077393	-1.633242	7.000000	0.140000	0.140000
0.206757	-1.078329	6.000000	0.120000	0.260000
0.336121	-0.523416	8.000000	0.160000	0.420000
0.465485	0.031498	6.000000	0.120000	0.540000
0.594849	0.586411	13.000000	0.260000	0.800000
0.724213	1.141324	8.000000	0.160000	0.960000
0.853577	1.696238	2.000000	0.040000	1.000000

3.2.4. Medidas de Tendencia Central y Dispersión Muestrales

Medida	Carbs(g)
Media	0.458142
Q_1	0.258305
Q_2	0.501985
Q_3	0.650737
Desviación Estándar	0.233125
Mínimo	0.012711
Máximo	0.918259
Asimetría de Fisher	-0.226386

3.2.5. Comparativa con las Medidas Poblacionales

media, q1, q2, q3, std, min, max, asimetría

Si se compara con las medidas poblacionales, se puede observar que todos los valores muestrales difieren de los mismos, en mayor o menor medida. Esto refleja que el muestreo no es representativo para estimar las medidas poblacionales. Siendo la asimetría el valor que más difiere debido a que es un valor negativa; por lo que se observa una distribución diferente.

